

Proyecto Final — Clase 2: Predicción del estado fetal a partir de CTG

Autor: Lino Bossio **Dataset:** ASI_casoPractico.csv — 2126 cardiotocogramas (CTG) fetales, 22 variables explicativas y 1 variable objetivo (Target) **Notebook adjunto:** sprint_final_LinoBossio.ipynb

1. Análisis descriptivo de las variables explicativas y el target

El dataset recoge características diagnósticas extraídas de registros de cardiotocografía (frecuencia cardíaca fetal, movimientos fetales, contracciones uterinas y estadísticos del histograma de FCF), clasificadas por consenso de tres obstetras. Se eliminan ID, b, e (identificador e instantes de inicio/fin del segmento, sin valor predictivo) y DR (deceleraciones repetitivas), que toma un único valor (0) en las 2126 observaciones.

Target. Target = 0 (normal) / 1 (anormal) está **desbalanceado**: 1655 registros normales (77.85 %) frente a 471 anormales (22.15 %). Este desbalance obliga a mirar más allá de la precisión global al validar el modelo (una precisión alta se puede lograr prediciendo siempre la clase mayoritaria), de ahí la importancia de la curva ROC y la matriz de confusión.

Variables explicativas más relevantes. Según la correlación (en valor absoluto) de cada variable con el target, las más influyentes son ASTV (0.493, % de tiempo con variabilidad de corto plazo anormal), ALTV (0.489, % de tiempo con variabilidad de largo plazo anormal), AC (0.369, número de aceleraciones) y DP (0.341, deceleraciones prolongadas). El resto de variables (frecuencia base, estadísticos del histograma de FCF, contracciones uterinas) aportan señal moderada o baja.

Variable nueva creada. Se construyó $Abn_Variability = ASTV + ALTV$, que combina en un único indicador el porcentaje de tiempo con variabilidad anormal a corto y largo plazo. Su correlación con el target (0.575) supera a la de sus dos componentes por separado, por lo que se incorpora como variable explicativa adicional. Se probó también $Decel_Total = DL + DS + DP$, pero se descartó: su

correlación (0.033) es muy inferior a la de DP aislada (0.341), porque DL y DS son casi siempre cero y diluyen la señal de DP al sumarlas.

2. División del conjunto de datos en entrenamiento y test

Se reutiliza el mismo muestreo definido en los sprints 5 y 6: **60 % entrenamiento / 40 % test**, con `random_state=0` para que el resultado sea reproducible y comparable entre algoritmos.

Conjunto	Observaciones	%
Entrenamiento	1275	60 %
Test	851	40 %

3. Algoritmo seleccionado e hiperparámetros

Se ajustaron y compararon tres modelos sobre el mismo *split*:

1. **Naive Bayes** (GaussianNB, sin hiperparámetros a ajustar).
2. **SVM con valores por defecto** (SVC, kernel rbf, $C=1.0$, `gamma='scale'`).
3. **SVM con hiperparámetros optimizados** mediante GridSearchCV (`scoring='roc_auc'`, `cv=3`) sobre la rejilla: kernel $\in \{\text{rbf}, \text{linear}, \text{poly}\}$, $C \in \{0.1, 1, 10\}$, $\gamma \in \{1e-3, 1e-4\}$ (solo rbf), `degree` $\in \{2, 3\}$ (solo poly).

La búsqueda de hiperparámetros identificó como mejor combinación **kernel lineal, $C=1$** (AUC medio en validación cruzada: 0.961). Este es el **algoritmo final seleccionado**: un SVM de kernel lineal con $C=1$ (resto de hiperparámetros por defecto de `scikit-learn`).

4. Validación: curva ROC, AUC, matriz de confusión y precisión

Modelo	AUC train	AUC test	Precisión train	Precisión test
Naive Bayes	0.9499	0.9381	0.8886	0.8872
SVM (por defecto)	0.9378	0.9217	0.8784	0.8719
SVM ajustado (Grid Search)	0.9710	0.9610	0.9184	0.9048

Matrices de confusión del modelo final (SVM ajustado, kernel lineal, C=1):

Entrenamiento (1275 obs.):

	Predicho Normal	Predicho Anormal
Real Normal	949	50
Real Anormal	54	222

Test (851 obs.):

	Predicho Normal	Predicho Anormal
Real Normal	629	27
Real Anormal	54	141

Lectura de resultados. El SVM ajustado supera claramente tanto a Naive Bayes como al SVM con valores por defecto, tanto en AUC como en precisión, en entrenamiento y en test. La diferencia entre AUC de entrenamiento (0.971) y de test (0.961) es pequeña (≈ 0.01), al igual que la diferencia de precisión (≈ 1.4 puntos porcentuales): **no hay indicios de sobreajuste** relevante, pese a que el modelo ajustado es más complejo (kernel lineal calibrado vía validación cruzada) que el SVM con valores por defecto. En la matriz de confusión de test, el modelo comete 54 falsos negativos (anormales clasificados como normales) y 27 falsos positivos — en un contexto clínico, los falsos negativos son el error más costoso, y siguen siendo la principal limitación del modelo pese a la mejora obtenida.

Conclusión. El algoritmo final entregado es un **SVM con kernel lineal y $C=1$** , seleccionado por GridSearchCV optimizando AUC en validación cruzada, con un AUC de test de **0.961** y una precisión de test de **90.48 %**, sin sobreajuste apreciable respecto al conjunto de entrenamiento.